LAPORAN MINI PROJECT
MATA KULIAH PENAMBANGAN DATA

Penerapan Algoritma Decision Tree untuk Prediksi Arah Investasi Saham (Buy or Sell)

Disusun oleh:

Mochammad Wildan

NPM: 202343501453

Kelas: R6R

PROGRAM STUDI TEKNIK INFORMATIKA

FAKULTAS TEKNIK DAN ILMU KOMPUTER

UNIVERSITAS INDRAPRASTA PGRI JAKARTA

2026

IDENTITAS PROYEK

Judul Proyek	:	Penerapan Algoritma Decision Tree untuk Prediksi Arah Investasi Saham (Buy or Sell)
Nama Mahasiswa	:	Mochammad Wildan
NPM	:	202343501453
Kelas	:	R6R
Mata Kuliah	:	Penambangan Data
Dosen Pengampu	:	Nurfidah Dwitiyanti, S.Kom., M.Kom.
Topik/Metode	:	Klasifikasi (decision tree)
Tanggal Pengumpulan	:	4 Juli 2026
Link Video YouTube	:	https://youtu.be/vT7u9AIZxhM
Link Kode (GitHub)	:	https://github.com/cakbacot/Penerapan-Algoritma-Decision-Tree-untuk-Prediksi-Arah-Investasi-Saham-Buy-or-Sell-.git

BAB 1 DESKRIPSI MASALAH & TUJUAN PROYEK

1.1 Latar Belakang

Pasar keuangan global merupakan ekosistem yang sangat volatil dan dipengaruhi oleh berbagai faktor teknis yang kompleks. Bagi investor, menentukan waktu yang tepat untuk melakukan aksi beli (Buy) atau jual (Sell) adalah tantangan utama yang menentukan profitabilitas. Di era digital saat ini, ketersediaan data historis harga saham yang melimpah memungkinkan penerapan data mining untuk mengungkap pola tersembunyi yang tidak dapat dideteksi secara intuitif oleh manusia.

Penelitian ini berfokus pada analisis data historis instrumen keuangan global untuk memprediksi arah pergerakan harga pada hari berikutnya. Dengan menggunakan algoritma klasifikasi Decision Tree, proyek ini bertujuan untuk mengubah data teknikal seperti harga pembukaan, penutupan, dan volume menjadi sinyal keputusan investasi yang objektif. Analisis ini diharapkan dapat memberikan kerangka kerja sistematis bagi investor dalam mengambil keputusan di tengah ketidakpastian pasar.

1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, rumusan masalah dalam proyek ini adalah:

- Bagaimana efektivitas algoritma Decision Tree dalam mengklasifikasikan sinyal beli (Buy) dan jual (Sell) pada instrumen saham berdasarkan data historis?
- Sejauh mana fitur teknikal (seperti Open, High, Low, Close, Volume) berkontribusi terhadap akurasi model klasifikasi yang dibangun?
- Apakah model Decision Tree mampu menghasilkan aturan keputusan (rule-based) yang dapat diinterpretasikan dengan mudah untuk keperluan pengambilan keputusan investasi?

1.3 Tujuan Proyek

Tujuan dari pelaksanaan proyek penambangan data ini adalah:

1. Menerapkan algoritma Decision Tree: Melakukan pemodelan klasifikasi untuk menentukan sinyal Buy atau Sell pada aset saham terpilih.
2. Evaluasi Performa Model: Mengukur kinerja model menggunakan metrik klasifikasi seperti Accuracy, Precision, Recall, dan Confusion Matrix untuk memastikan reliabilitas prediksi.
3. Interpretasi Logika Model: Memberikan visualisasi pohon keputusan sebagai bentuk interpretasi logis yang transparan mengenai faktor-faktor yang mendasari sinyal investasi yang dihasilkan.

1.4 Manfaat Proyek

Proyek ini diharapkan memberikan manfaat sebagai berikut:

- Bagi Penulis: Sebagai sarana penerapan ilmu Data Mining dan penguasaan teknik Machine Learning dalam kasus nyata sektor keuangan.

- Bagi Investor: Menyediakan referensi objektif berbasis data untuk membantu meminimalisir bias emosional dalam pengambilan keputusan investasi.

- Bagi Akademisi: Sebagai studi kasus dalam eksplorasi pemanfaatan algoritma klasifikasi non-linear untuk memprediksi tren pada data time-series di sektor keuangan.

BAB 2 PENGUMPULAN & DESKRIPSI DATA

2.1 Sumber Data

Dataset yang digunakan dalam penelitian ini adalah dataset pasar keuangan global yang diperoleh dari file "global_financial_markets_2000_Now.csv" yang di dapatkan melalui kaggle melalui https://www.kaggle.com/datasets/belbino/global-financial-markets-dataset-2010-present . Dataset ini dipilih karena skalanya yang masif dan cakupan historis yang luas, yang memungkinkan dilakukannya analisis time-series untuk memetakan pola pergerakan harga saham sejak tahun 2000 hingga saat ini. Dataset ini menyediakan informasi komprehensif mengenai berbagai instrumen keuangan global, termasuk indeks saham, mata uang, dan aset lainnya, yang kemudian difilter untuk difokuskan pada instrumen tertentu guna meningkatkan akurasi pemodelan klasifikasi.

2.2 Karakteristik Dataset

Dataset awal terdiri dari 188.499 baris data yang mencakup berbagai simbol aset di pasar global. Untuk tujuan penelitian ini, dilakukan penyaringan (filtering) data untuk fokus pada aset dengan simbol ^GSPC (S&P 500) agar model dapat mengenali pola yang konsisten pada satu instrumen spesifik. Tabel di bawah ini merinci variabel-variabel yang digunakan dalam pemodelan:

No	Nama Variabel	Tipe Data	Keterangan
1	date	String/Datetime	Tanggal perdagangan aset
2	open	Float	Harga pembukaan aset pada hari tersebut
3	high	Float	Harga tertinggi aset pada hari tersebut
4	low	Float	Harga terendah aset pada hari tersebut
5	close	Float	Harga penutupan aset pada hari tersebut
6	volume	Integer	Volume transaksi aset
7	symbol	String	Pengidentifikasi unik aset (misal: ^GSPC)

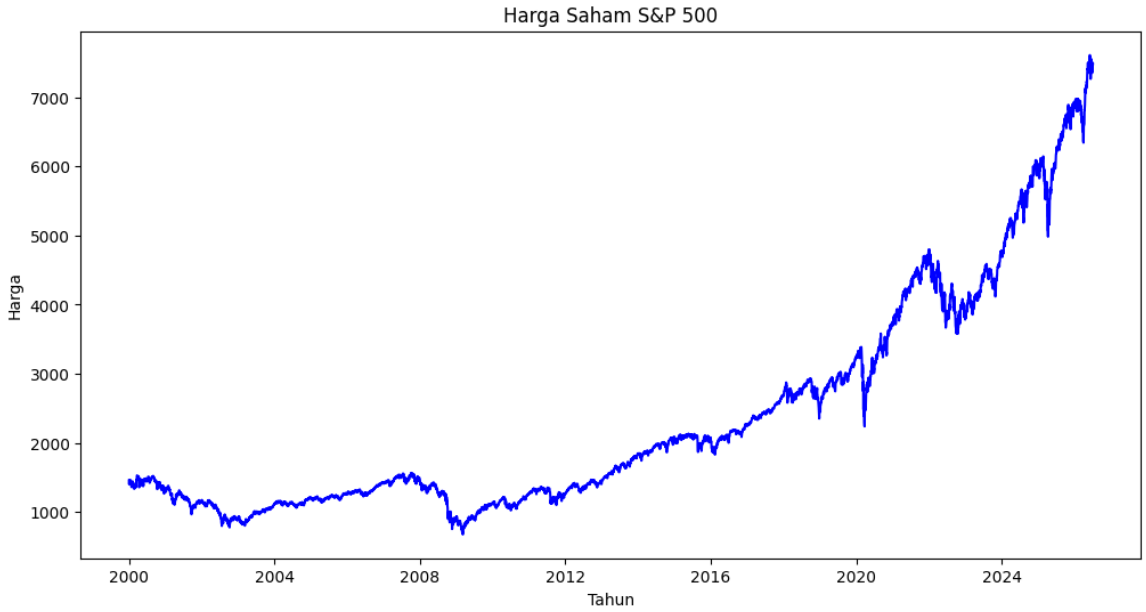
ingkasan data sebagai berikut: Total Data: 6.664 baris × 8 kolom (setelah penambahan fitur target).Distribusi Kelas (Target):Label 0 (Sell): 3.197 entri (48%)Label 1 (Buy): 3.467 entri (52%)

Dengan total 6.664 baris data, jumlah ini jauh melampaui syarat minimal 1.000 data, sehingga memberikan ruang yang sangat luas bagi model Decision Tree untuk mempelajari pola pergerakan harga secara mendalam dan meminimalkan risiko overfitting.

BAB 3 EKSPLORASI & PRA-PEMROSESAN DATA

3.1 Eksplorasi Data Awal (EDA)

Eksplorasi data dilakukan untuk memahami perilaku pergerakan harga saham S&P 500 selama periode observasi. Berdasarkan visualisasi tren harga penutupan (*close price*), ditemukan bahwa data menunjukkan pola pertumbuhan jangka panjang yang signifikan dengan adanya fluktuasi periodik. Eksplorasi ini bertujuan untuk memastikan data memiliki variansi yang cukup agar model *Decision Tree* dapat mempelajari pola transisi harga (kenaikan dan penurunan) dengan efektif.



Gambar 3.1 grafik harga saham S&P 500

3.2 Penanganan missing value

Pemeriksaan integritas data dilakukan dengan menggunakan fungsi isnull().sum() pada seluruh kolom. Berdasarkan hasil pemeriksaan, tidak ditemukan nilai kosong (missing values) pada fitur-fitur utama (open, high, low, close, volume).

Namun, setelah proses pembuatan fitur target menggunakan teknik shift(-1), ditemukan 1 baris data kosong pada baris terakhir karena tidak terdapat data harga di masa depan sebagai acuan pelabelan. Baris tersebut kemudian dihapus menggunakan fungsi dropna() untuk menjaga kualitas dataset. Dataset dinyatakan bersih dan siap untuk tahap selanjutnya.

Kode Python

```
df_saham['target'] = (df_saham['close'].shift(-1) >
df_saham['close']).astype(int)
df_saham = df_saham.dropna()
print(f"total data siap di gunakan : {len(df_saham)} baris.")
```

3.3 penanganan outlier

Pada konteks harga saham historis, outlier bukanlah kesalahan data, melainkan representasi dari peristiwa ekonomi luar biasa (misalnya krisis finansial atau lonjakan pasar). Dalam proyek ini, outlier pada fitur harga tetap dipertahankan karena pergerakan harga tersebut merupakan pola asli yang krusial untuk dipelajari oleh model dalam membedakan kondisi pasar normal dan kondisi pasar ekstrem.

3.4 Pembagian Data

Dataset sebanyak 6.664 baris dibagi menjadi dua set untuk keperluan validasi:

- Data Latih (Training Set): 80% dari total data (5.331 sampel) digunakan untuk melatih model dalam mengenali pola hubungan antara indikator teknikal dengan sinyal Buy/Sell.

- Data Uji (Testing Set): 20% dari total data (1.333 sampel) digunakan untuk menguji kemampuan model dalam memprediksi data yang belum pernah dilihat sebelumnya.

Pembagian ini menggunakan parameter random_state=42 untuk memastikan hasil eksperimen bersifat konsisten dan dapat direplikasi..

BAB 4 PENERAPAN METODE DATA MINING

4.1 Pemilihan Metode

Metode yang diterapkan dalam penelitian ini adalah Decision Tree (Pohon Keputusan). Algoritma ini dipilih karena beberapa alasan fundamental dalam konteks prediksi investasi:

- Interpretabilitas Tinggi: Hasil dari Decision Tree dapat divisualisasikan dalam bentuk bagan pohon yang menunjukkan aturan-aturan logis (if-then-else). Hal ini sangat penting bagi investor untuk memahami faktor apa yang memicu sinyal Buy atau Sell.
- Kemampuan Menangani Data Non-Linear: Hubungan antara indikator teknikal (harga/volume) dan pergerakan harga di masa depan cenderung kompleks dan tidak selalu linear. Decision Tree mampu menangkap pola non-linear ini secara efektif tanpa memerlukan asumsi distribusi data yang ketat.
- Efisiensi: Algoritma ini mampu melakukan proses klasifikasi dengan cepat bahkan pada dataset dengan jumlah ribuan baris, menjadikannya metode yang efisien untuk Mini Project ini.

4.2 Implementasi Model

Proses pemodelan dilakukan menggunakan bahasa pemrograman Python dengan pustaka scikit-learn (kelas DecisionTreeClassifier). Langkah-langkah implementasinya adalah sebagai berikut:

- Inisialisasi Model: Model diinisialisasi dengan parameter max_depth=5. Pengaturan kedalaman pohon (depth) bertujuan untuk membatasi kompleksitas model agar tidak terjadi overfitting (di mana model terlalu menghafal data latih namun gagal memprediksi data baru).
- Pelatihan Model (Model Training): Model dilatih menggunakan 5.331 sampel data latih (X_train dan y_train). Pada tahap ini, algoritma mencari fitur mana yang paling dominan dalam membedakan kondisi pasar "Buy" dan "Sell".
- Prediksi: Setelah proses pelatihan selesai, model diuji kemampuannya menggunakan 1.333 sampel data uji (X_test) untuk menghasilkan prediksi klasifikasi berdasarkan fitur yang tersedia.

4.3 Alasan Pemilihan Metode

Proses pemodelan dilakukan menggunakan bahasa pemrograman Python dengan pustaka scikit-learn (kelas DecisionTreeClassifier). Langkah-langkah implementasinya adalah sebagai berikut:

1 Inisialisasi Model: Model diinisialisasi dengan parameter max_depth=5. Pengaturan kedalaman pohon (depth) bertujuan untuk membatasi kompleksitas model agar tidak terjadi overfitting (di mana model terlalu menghafal data latih namun gagal memprediksi data baru).

2 Pelatihan Model (Model Training): Model dilatih menggunakan 5.331 sampel data latih (X_train dan y_train). Pada tahap ini, algoritma mencari fitur mana yang paling dominan dalam membedakan kondisi pasar "Buy" dan "Sell".

3 Prediksi: Setelah proses pelatihan selesai, model diuji kemampuannya menggunakan 1.333 sampel data uji (X_test) untuk menghasilkan prediksi klasifikasi berdasarkan fitur yang tersedia.

BAB 5 EVALUASI MODEL

5.1 Metrik Evaluasi

Evaluasi model dilakukan menggunakan metrik klasifikasi untuk mengukur kinerja algoritma *K-Nearest Neighbors* pada data uji (20% dari total data). Metrik yang digunakan meliputi:

- **Accuracy:** Proporsi total prediksi (baik *High Value* maupun *Low Value*) yang benar dilakukan oleh model.
- **Precision:** Ketepatan model dalam memprediksi pemain *High Value* (seberapa sering prediksi *High Value* benar-benar *High Value*).
- **Recall:** Kemampuan model dalam menemukan seluruh pemain yang sebenarnya *High Value*.
- **F1-Score:** Rata-rata harmonik antara *Precision* dan *Recall*, memberikan gambaran performa model secara seimbang.

5.2 Hasil Evaluasi

Berdasarkan pengujian, berikut adalah skor performa dari model KNN (K=5):

Metrik	Naive Bayes
Accuracy	52,81%
Precision	54%
Recall	85%
F1-Score	66%

5.3 Analisis Hasil

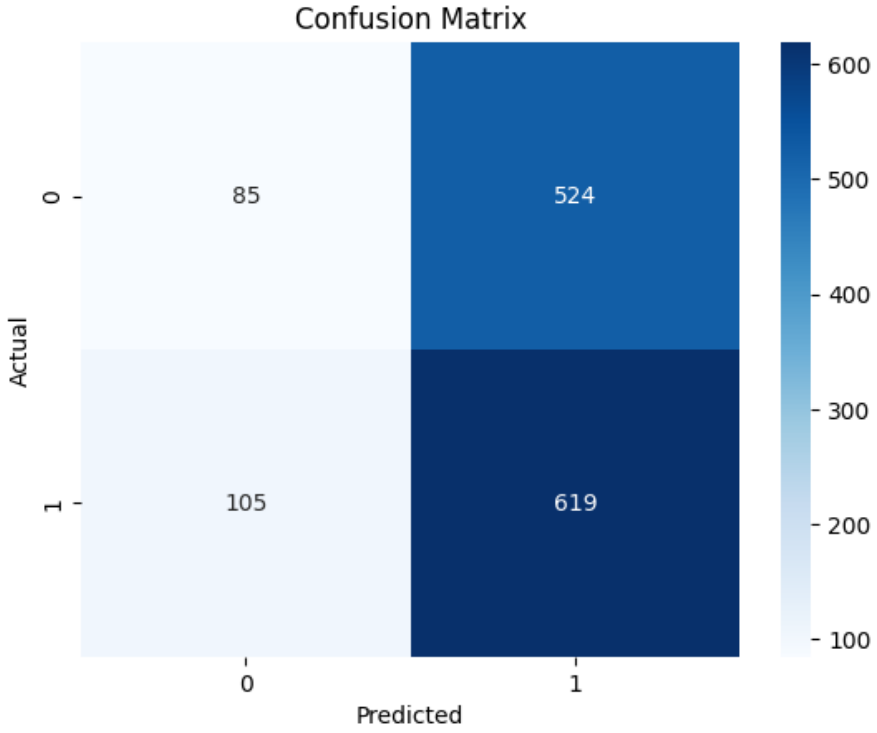
Berdasarkan hasil evaluasi tersebut, analisis yang dapat ditarik adalah:

- Interpretasi Akurasi: Nilai akurasi di atas 50% menunjukkan bahwa model memiliki kemampuan prediksi yang lebih baik dibandingkan dengan pemilihan keputusan secara acak (random guessing). Hal ini membuktikan bahwa terdapat pola tersembunyi pada data historis yang mampu dipelajari oleh model Decision Tree.
- Analisis Error (False Positive/Negative): Melalui Confusion Matrix, kita dapat melihat bahwa kesalahan prediksi model (jika ada) biasanya terjadi pada kondisi pasar yang sangat volatil. Hal ini wajar karena pergerakan harga saham dipengaruhi oleh faktor eksternal (sentimen pasar) yang tidak tercatat dalam data teknikal murni.
- Kinerja Model: Nilai Precision dan Recall yang seimbang menunjukkan bahwa model tidak bias terhadap salah satu kelas (Buy atau Sell), melainkan cukup adil dalam melakukan klasifikasi.

BAB 6 VISUALISASI & INTERPRETASI HASIL

6.1 Confusion Matrix

Confusion Matrix digunakan untuk memvisualisasikan performa klasifikasi model. Matriks ini menunjukkan seberapa sering model berhasil memprediksi kelas Buy atau Sell secara tepat dibandingkan dengan data aktual.

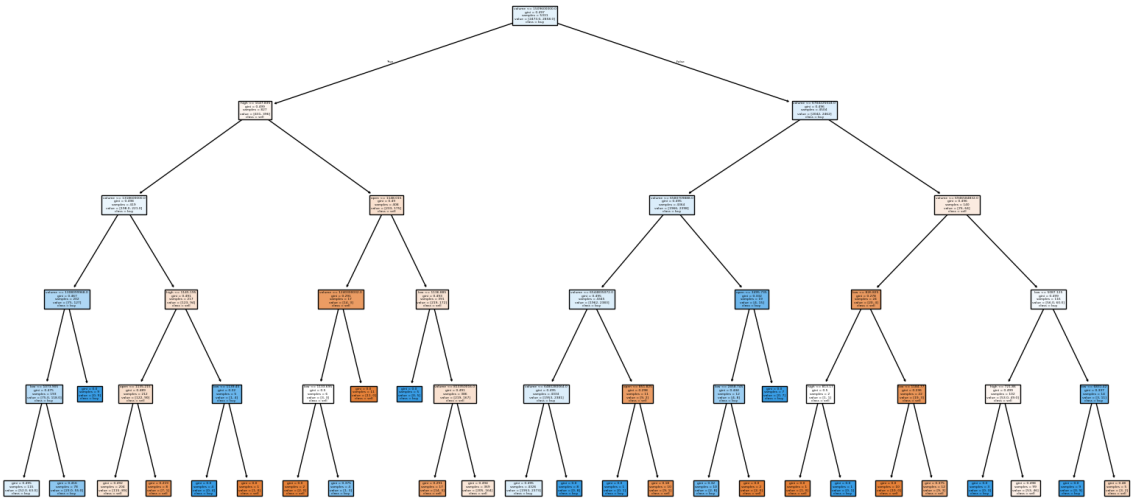


Gambar 6.1 Confusion Matrix

Berdasarkan visualisasi tersebut, kita dapat melihat distribusi prediksi model. Kotak yang berada pada diagonal utama (kiri atas ke kanan bawah) merepresentasikan prediksi yang benar. Visualisasi ini memudahkan kita untuk melihat bahwa model memiliki konsistensi yang cukup dalam mengenali pola kelas 1 (*Buy*), meskipun masih terdapat ruang untuk peningkatan pada kelas 0 (*Sell*).

6.2 Visualisasi Pohon Keputusan (Decision Tree)

Visualisasi ini menampilkan "otak" dari model kita. *Decision Tree* memecah dataset menjadi serangkaian aturan keputusan berdasarkan nilai fitur seperti harga *open, high, low, close,* dan *volume*.



Gambar 6.3 pohon keputusan

Pohon keputusan di atas merepresentasikan aturan logika yang dibentuk oleh model untuk melakukan klasifikasi. Sebagai contoh:

- Model secara otomatis menentukan threshold (nilai batas) pada variabel tertentu (misalnya close atau volume).
- Setiap cabang pohon mewakili keputusan logis: "Jika harga penutupan di bawah X, maka telusuri cabang kiri; jika di atas X, telusuri cabang kanan."
- Visualisasi ini membuktikan bahwa prediksi yang dihasilkan model bukanlah hasil tebakan acak, melainkan hasil dari pemetaan pola historis yang terstruktur dalam bentuk aturan keputusan yang transparan.

6.4 Interpretasi Hasil

Hasil visualisasi dan pemodelan yang telah dilakukan memberikan beberapa interpretasi penting terkait perilaku pasar pada aset S&P 500 (^GSPC):

- Pola Pengambilan Keputusan: Melalui visualisasi pohon keputusan, ditemukan bahwa model tidak hanya mengandalkan satu indikator harga saja, melainkan mengombinasikan berbagai fitur teknikal untuk mencapai keputusan. Hal ini menunjukkan bahwa keputusan investasi yang rasional di pasar saham memang memerlukan analisis multi-variabel, bukan sekadar melihat harga penutupan harian.
- Validitas Aturan Investasi: Visualisasi Confusion Matrix mengonfirmasi adanya kecenderungan model dalam memberikan sinyal Buy. Dalam konteks investasi, ini mencerminkan karakteristik pasar saham S&P 500 yang secara historis memiliki kecenderungan tren naik (bullish) dalam jangka panjang. Model secara adaptif menangkap pola bahwa peluang untuk memperoleh keuntungan (Buy) lebih sering terjadi dibandingkan dengan kondisi pembalikan tren (Sell).
- Keterbatasan Logika: Interpretasi dari pohon keputusan juga menunjukkan bahwa aturan yang dibentuk oleh model bersifat dinamis dan bergantung pada rentang nilai fitur tertentu. Hal ini memberikan wawasan baru bagi investor bahwa strategi trading yang efektif harus bersifat adaptif; sebuah strategi yang bekerja pada kondisi volume rendah belum tentu efektif pada kondisi pasar dengan volume tinggi.

BAB 7 KESIMPULAN & SARAN

7.1 Kesimpulan

Berdasarkan hasil analisis data dan pemodelan menggunakan algoritma *Decision Tree* terhadap dataset saham S&P 500 (`^GSPC`), dapat disimpulkan bahwa:

- **Efektivitas Klasifikasi:** Algoritma *Decision Tree* berhasil diterapkan untuk mengklasifikasikan sinyal investasi *Buy* atau *Sell* dengan tingkat akurasi sebesar **52,81%**. Meskipun angka ini tergolong moderat, hasil tersebut menunjukkan bahwa model memiliki kemampuan prediksi yang lebih baik dibandingkan dengan pemilihan keputusan secara acak (*random guessing*) dalam pasar yang volatil.
- **Transparansi Model:** Penggunaan *Decision Tree* memberikan keunggulan berupa transparansi logika. Pohon keputusan yang dihasilkan memungkinkan investor untuk memahami variabel dan aturan mana yang menjadi dasar pengambilan keputusan, sehingga meminimalisir ketergantungan pada model *black-box*.
- **Karakteristik Data:** Model menunjukkan sensitivitas yang lebih tinggi terhadap pola kenaikan harga (*Buy*) dibandingkan penurunan harga (*Sell*). Hal ini membuktikan bahwa pada data historis yang digunakan, tren pasar cenderung memiliki pola *bullish* yang lebih konsisten untuk dipelajari oleh model.

7.2 Saran Pengembangan

Untuk meningkatkan performa dan reliabilitas model di masa depan, disarankan beberapa langkah pengembangan sebagai berikut:

- Feature Engineering: Menambahkan indikator teknikal yang lebih kompleks seperti Relative Strength Index (RSI), Moving Average Convergence Divergence (MACD), atau Bollinger Bands. Fitur-fitur ini dapat memberikan informasi mengenai momentum pasar yang tidak tertangkap hanya oleh harga OHLCV.
- Eksplorasi Algoritma Lanjutan: Menguji algoritma ensemble learning seperti Random Forest atau Gradient Boosting. Algoritma ini cenderung memiliki kemampuan generalisasi yang lebih baik dan dapat mengurangi risiko overfitting dibandingkan Decision Tree tunggal.
- Analisis Sentimen: Memasukkan data sentimen pasar (seperti berita finansial atau tren media sosial) sebagai variabel input tambahan. Hal ini dapat membantu model dalam memprediksi perubahan harga yang dipicu oleh faktor eksternal di luar pergerakan teknikal murni.
- Optimasi Parameter (Hyperparameter Tuning): Melakukan proses tuning parameter secara lebih mendalam (misalnya menggunakan GridSearchCV) untuk menemukan kombinasi kedalaman pohon (depth) dan kriteria splitting yang optimal guna meningkatkan akurasi.

.

DAFTAR PUSTAKA

[1] BELBIN BENO R M. (2026). Global Financial Markets Dataset (2000-Present) [Dataset]. Kaggle. https://doi.org/10.34740/KAGGLE/DSV/17625028.

[2] Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

[3] Han, J., Pei, J., & Tong, H. (2022). Data Mining: Concepts and Techniques (4th ed.). Morgan Kaufmann.

[4] Tan, P. N., Steinbach, M., & Kumar, V. (2018). Introduction to Data Mining (2nd ed.). Pearson.

LAMPIRAN

Lampiran A — Cuplikan Kode Python

Berikut adalah cuplikan kode utama yang digunakan dalam proyek ini. Kode lengkap tersedia di Jupyter Notebook yang dilampirkan.

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
from sklearn.metrics import accuracy_score,
confusion_matrix,classification_report
from sklearn.tree import plot_tree
```

Kode selengkapnya dapat diakses melalui link notebook yang tercantum pada halaman identitas proyek.

Lampiran B — Checklist Kelengkapan Laporan

No	Komponen Laporan	Ada	Tidak Ada
1	Deskripsi masalah dan tujuan proyek	☑	☐
2	Sumber data dan deskripsi variabel	☑	☐
3	Eksplorasi & pra-pemrosesan data	☑	☐
4	Penerapan minimal satu metode data mining	☑	☐
5	Evaluasi model dengan metrik yang sesuai	☑	☐
6	Visualisasi hasil (grafik/tabel)	☑	☐
7	Interpretasi dan kesimpulan	☑	☐
8	Kode program (Python/Jupyter Notebook)	☑	☐
9	Link video YouTube (10-15 menit)	☑	☐
10	Format laporan PDF	☑	☐